

B-49

Correção e Validação da Race Condition em **ConversationService#upsertFromWebhook**

Auditoria arquitetural completa — diagnóstico, comparação de alternativas,
implementação e validação de concorrência real contra PostgreSQL

Data: 2026-08-01

Projeto: AtendeHub (apps/api — NestJS · Prisma · PostgreSQL · Bull)
Status: ' Corrigido, validado e pronto para produção

Gerado por Claude Sonnet 5 (Claude Code) — Anthropic

1. Sumário executivo

Durante a auditoria arquitetural de fechamento do B-48 (idempotência de mensagens de webhook), o mapeamento completo do fluxo Webhook !' Queue !' Processor !' Service !' PostgreSQL revelou que ConversationService#upsertFromWebhook tinha o mesmo padrão estrutural de falha (check-then-act não atômico), mas aplicado a um recurso diferente — Conversation, não Message — e com uma invariante de unicidade mais complexa: não é "um valor de coluna nunca se repete", é "no máximo uma conversa ATIVA por contato", uma condição que depende do campo status.

Esta auditoria confirma a causa raiz de forma independente (não presume que a solução do B-48 se aplica igual), compara 7 alternativas de correção, implementa a escolhida — índice único PARCIAL no PostgreSQL, algo que o B-48 não precisou — e valida com concorrência real (não mock) contra PostgreSQL: 2, 5, 10, 50 e 100 chamadas verdadeiramente simultâneas para o mesmo contato, em todas as rodadas resultando em exatamente 1 conversa ativa.

Resultado: bug de concorrência real (não apenas teórico — o gatilho mais comum nem precisa de retry, basta o cliente mandar duas mensagens seguidas) eliminado sem mutex, sem lock distribuído, sem transação SERIALIZABLE — a garantia vem do próprio PostgreSQL. Suíte automatizada (348 !' 354 testes), E2E e build/lint/typecheck seguem 100% verdes.

2. Diagnóstico completo e causa raiz

2.1 Onde a conversa é identificada

- Chave lógica: (companyId, contactId) — uma conversa é "do contato", não de uma sessão/conexão específica.
- NÃO existe externalId de conversa (diferente de Message) — o WhatsApp não tem um "id de conversa"; ela é um agrupamento lógico interno do AtendeHub.
- A invariante de negócio real é CONDICIONAL: no máximo 1 linha com status IN (WAITING, OPEN) por (companyId, contactId). Conversas RESOLVED/CLOSED do mesmo contato continuam existindo livremente — são o histórico de atendimentos passados, não um estado que a unicidade deve proteger.
- Antes desta correção: schema.prisma só tinha @@index([companyId, contactId]) — um índice de performance, sem nenhuma garantia de unicidade.
- Único ponto de criação de Conversation em todo o backend: ConversationService#upsertFromWebhook (confirmado por busca em todo apps/api/src — nenhum outro .create()).

2.2 TOCTOU confirmado

Confirmado por leitura direta do código (conversation.service.ts, versão anterior a esta correção): findFirst({companyId, contactId, status: {in:[WAITING,OPEN]}}) seguido de create() sem nenhuma transação, lock ou constraint entre as duas operações — Time-Of-Check / Time-Of-Use clássico.

2.3 Linha do tempo da race condition


```
t0      Worker A: findFirst(contato=X, status ativo) -> null
t0+;R   v÷&¶W" #¢ f-æDf-'7B†6öçF FóÔ,Â 7F GW2 F-fò' Óâ çVÆÂ  „  -æF î6ò FW&Ö-æ÷R•
t1      Worker A: create() -> Conversation #1 (WAITING) [msg 1 do cliente]
t1+;R   v÷&¶W" #¢ 7&V FR,' Óâ 6öçfW'6 F-ôâ 3" ...t •D"är' ¶×6r " Fò 6Æ-VçFRÂ 7 Æ-BÖ'& -âÐ
```

Gatilho realista: cliente manda 2 mensagens seguidas no WhatsApp (comum).
Cada mensagem -> 1 evento de webhook -> 1 job na fila -> processado por
workers/réplicas diferentes quase ao mesmo tempo. NÃO depende de retry.

Consequência é mais severa que a duplicação de mensagem do B-48: as duas mensagens do MESMO cliente passam a viver em DUAS conversas diferentes. Um agente responde na #1; a próxima mensagem do cliente resolve para a #2 (mais recente, orderBy createdAt desc) — a #1 vira uma ficha fantasma na fila, visível mas que nunca mais receberá resposta do cliente por aquele canal.


3. Fluxogramas — antes e depois

3.1 Fluxo antigo (com a falha)



Resultado sob concorrência: 2+ linhas de Conversation ativas para o mesmo contato — nenhuma barreira as impede.

3.2 Fluxo novo (corrigido)



Resultado sob concorrência: o PostgreSQL rejeita a 2ª tentativa de INSERT (unique_violation) antes dela existir — a corrida é resolvida pelo banco, não pela aplicação.

4. Modelo de dados — antes e depois

Aspecto	Antes	Depois
Índices em (companyId, contactId)	@@index (não-único)	@@index (mantido, performance) + índice ÚNICO PARCIAL (integridade)
Constraint de unicidade	Nenhuma	conversations_active_per_contact_key — UNIQUE(companyId, contactId) WHERE status IN (WAITING, OPEN)
Expressável via @@unique do Prisma?	N/A	Não — Prisma não suporta WHERE em @@unique/@@index (DSL sem índice parcial). Migration SQL manual.
Conversas RESOLVED/CLOSED do mesmo contato	Múltiplas, sem restrição	Múltiplas, sem restrição (inalterado — é o histórico esperado)
Conversas ativas (WAITING/OPEN) por contato	Sem limite garantido pelo banco	No máximo 1, garantido pelo PostgreSQL

5. Comparação de alternativas

#	Alternativa	Veredito e motivo
1	Mutex local (em memória)	Descartada — não sobrevive a múltiplas réplicas da API, que é justamente o cenário que amplia a corrida.
2	Redis lock (SET NX / Redlock)	Descartada — resolveria, mas adiciona coordenação distribuída externa para um problema que o PostgreSQL já resolve nativamente com uma constraint. Também protegeria mais do que o necessário (a leitura da fila ativa não precisa de lock).
3	Prisma upsert() puro	Tecnicamente inviável aqui — upsert() do Prisma só é atômico (ON CONFLICT nativo) quando o where aponta para um @@unique NÃO-parcial conhecido pelo schema. A invariante é condicional (WHERE status IN ...), Prisma não expressa isso.
4	UNIQUE constraint (parcial) + tratamento de P2002	ESCOLHIDA — atomicidade garantida pelo PostgreSQL dentro do próprio INSERT; sem lock, sem infraestrutura nova, sem retry loop.

- | | | |
|---|---|--|
| 5 | SELECT FOR UPDATE | Viável mas inferior — exige travar uma linha "proxy" (ex.: Contact) dentro de uma transação aberta, aumentando contenção em qualquer outra operação sobre aquele contato; garantia só de aplicação (quebra de novo se outro código criar Conversation sem passar pelo lock — foi assim que o B-49 nasceu). |
| 6 | Transação SERIALIZABLE | Detectaria o conflito (write skew) via predicate lock (SIREAD), mas exige implementar retry para o erro 40001/P2034, com custo de throughput maior que um índice único para proteger uma invariante que não precisa de isolamento de transação inteira. |
| 7 | Coluna denormalizada (activeContactKey) + @@unique simples, para viabilizar upsert() nativo | Descartada conscientemente — trocaria uma migration SQL de uma linha por manutenção permanente em TODO lugar que muda status (updateStatus, assign), com risco real de esquecer de zerar a coluna e travar novas conversas do contato para sempre. |

6. Justificativa técnica da solução escolhida

O índice único PARCIAL move a garantia de unicidade para a única camada capaz de garanti-la sob qualquer grau de concorrência — o PostgreSQL — exatamente como no B-48, mas adaptado à natureza condicional da invariante deste caso (diferente do B-48, cuja unicidade era sobre a coluna inteira). O findFirst original foi mantido como fast-path: a maioria das mensagens pertence a uma conversa JÁ existente, então ler antes evita tentar um INSERT fadado a falhar em quase toda chamada — só o caminho raro (conversa nova) paga o custo do catch(P2002).

- Aderência ao PostgreSQL: índice parcial é mecanismo nativo e de primeira classe, não uma emulação em nível de aplicação.
- Aderência ao Prisma: P2002 é o único ponto de contato necessário — não depende de nenhum recurso do Prisma que não exista (como upsert()) faria).
- Ambiente distribuído / múltiplas réplicas / Bull: a garantia não depende de qual processo, worker ou réplica executa o create() — o PostgreSQL arbitra entre eles.
- Sem retry loop, sem lock held, sem aumento de latência no caminho comum (conversa já existente).

7. Arquivos alterados

Arquivo	Mudança
apps/api/prisma/schema.prisma	Comentário documentando o índice único parcial (não expressável via DSL)
apps/api/prisma/migrations/20260801211919_b49_conversation_active_unique_per_contact/migration.sql	Novo — CREATE UNIQUE INDEX ... WHERE status IN (WAITING, OPEN)
apps/api/src/modules/conversation/conversation.service.ts	upsertFromWebhook refatorado: try/catch(P2002) no create(); extraídos findActiveConversation() e reconnectIfNeeded()
apps/api/src/modules/conversation/conversation.service.upsert-from-webhook.spec.ts	Novo — 6 testes cobrindo existente/reconexão/corrida P2002/erro genérico/caminho feliz
apps/api/scripts/validate-b49-concurrency.ts	Novo — validação de concorrência real (2 a 100 workers) contra PostgreSQL
ROADMAP_ESTABILIZACAO.md	B-49 marcado concluído, changelog, painel atualizado

8. Diff resumido

```
conversation.service.ts
- const existing = await this.prisma.conversation.findFirst({...})
- if (existing) { ...update ou devolve... }
- const created = await this.prisma.conversation.create({...})
+ const existing = await this.findActiveConversation(companyId, contactId)
+ if (existing) return this.reconnectIfNeeded(existing, whatsappConnectionId)
+ try {
+   const created = await this.prisma.conversation.create({...})
+   ...
+ } catch (err) {
+   if (err instanceof Prisma.PrismaClientKnownRequestError && err.code === "P2002") {
+     const winner = await this.findActiveConversation(companyId, contactId)
+     return this.reconnectIfNeeded(winner, whatsappConnectionId)
+   }
+   throw err
+ }
```


9. Evidências — testes automatizados

Suíte	Antes do B-49	Depois do B-49	Resultado
Unitários (jest, backend completo)	348/348	354/354 (+6 novos em conversation.service.upsert-from-webhook.spec.ts)	PASS
E2E (test:e2e — SLA com Bull/Postgres reais)	3/3	3/3 (sem regressão)	PASS
TypeScript (tsc --noEmit)	limpo	limpo	PASS
ESLint	limpo	limpo	PASS
Build (nest build)	limpo	limpo	PASS

10. Evidências — concorrência real contra PostgreSQL

Script apps/api/scripts/validate-b49-concurrency.ts — instancia ConversationService real (não mock) contra Postgres real (docker compose), cria empresa/conexão/contato descartáveis, dispara N chamadas verdadeiramente concorrentes (Promise.all) de upsertFromWebhook para o MESMO contato.

Workers concorrentes	Conversas ativas no	isNew=true	IDs distintos	Rejeitadas	Tempo total
----------------------	---------------------	------------	---------------	------------	-------------

2	1	1	1	0	21ms
5	1	1	1	0	26ms
10	1	1	1	0	35ms
50	1	1	1	0	91ms
100	1	1	1	0	179ms

"IDs distintos devolvidos: 1" é a evidência mais forte — não só existe 1 linha no banco, como TODOS os N chamadores concorrentes (inclusive os que perderam a corrida) convergem e devolvem exatamente o mesmo conversationId . Nenhuma exceção não tratada em nenhuma das 5 rodadas.

11. Checklist de validação

- Mapeamento completo do fluxo (Webhook -> Postgres) feito antes de alterar código
- Causa raiz confirmada por leitura direta do código (não presumida)
- 7 alternativas de correção comparadas com prós/contras técnicos
- Solução escolhida com justificativa arquitetural (não a mais simples, a mais correta)
- Migration aplicada contra PostgreSQL real (prisma migrate deploy)
- Nenhuma duplicata pré-existente bloqueou a migration
- P2002 tratado sem mascarar outras exceções (erro genérico continua propagando)
- Validação de concorrência real (não mock) — 2/5/10/50/100 workers
- Todos os workers concorrentes convergem para o mesmo conversationId
- Nenhuma exceção não tratada durante a validação de concorrência
- Suíte unitária completa sem regressão (354/354)
- Suíte E2E sem regressão (3/3)
- TypeScript, lint e build limpos
- Auditoria de padrões TOCTOU semelhantes no resto do backend (herdada do B-48)
- Compatibilidade com B-39 (retry/DLQ) confirmada — ver seção 14
- Compatibilidade com B-48 (idempotência de Message) confirmada — ver seção 14
- Nenhuma regra de negócio alterada, nenhuma funcionalidade removida
- Documentação e changelog do roadmap atualizados

12. Análise de performance

12.1 Caminho comum (conversa já existente — ~99% das mensagens)

Inalterado: 1 findFirst, igual antes da correção. Nenhum overhead adicional — o try/catch só existe no branch de criação.

12.2 Caminho de criação sem corrida (conversa nova, sem concorrência)

Inalterado: 1 findFirst (não encontra) + 1 INSERT bem-sucedido. O índice único parcial adiciona um custo de escrita desprezível (mesma ordem de grandeza de qualquer índice B-tree adicional) comparado ao índice não-único que existia antes.

12.3 Caminho de colisão (raro — só sob concorrência genuína)

1 findFirst + 1 INSERT que falha (rejeição por índice, operação barata no PostgreSQL) + 1 SELECT de recuperação. Medido ao vivo: mesmo com 100 chamadas verdadeiramente simultâneas (99 delas percorrendo o caminho de colisão), o tempo total foi 179ms — sem lock global, sem fila de espera serializada.

12.4 Uso de CPU/memória/locks no PostgreSQL

Índice parcial ocupa menos espaço em disco que um índice completo equivalente (indexa só as linhas WAITING/OPEN, que são uma fração pequena do total histórico de conversas). Sem locks de longa duração — a verificação de unicidade acontece dentro do próprio INSERT, sem SELECT ... FOR UPDATE nem transação extra mantida aberta.

13. Compatibilidade com B-39 e B-48

13.1 Compatibilidade com B-39 (retry/DLQ de webhook)

O retry do Bull (B-39) é exatamente um dos gatilhos da concorrência que o B-49 fecha — um job que estourou WEBHOOK_TIMEOUT com a promise anterior ainda em voo agora pode colidir em upsertFromWebhook sem criar uma 2ª conversa: o P2002 é tratado, a execução "perdedora" devolve a mesma conversa da vencedora e o fluxo do webhook continua normalmente (mensagem anexada à conversa correta). Nenhuma mudança em webhook.errors.ts, webhook.processor.ts ou na política de retry/DLQ foi necessária — o erro nunca escapa até ali.

13.2 Compatibilidade com B-48 (idempotência de Message)

B-48 e B-49 protegem recursos diferentes (Message vs. Conversation) na mesma chamada de processMessage, mas são independentes: mesmo que upsertFromWebhook (B-49) e createFromWebhook (B-48) colidam ao mesmo tempo para o mesmo evento, cada um resolve sua própria corrida isoladamente via sua própria constraint. Testado junto na suíte completa (354/354) sem nenhuma interação inesperada entre os dois.

14. Riscos residuais

- `reconnectIfNeeded()` (reapontar `whatsappConnectionId`) não está protegido por lock — é uma operação idempotente (todos os racers escreveriam o mesmo valor final), então uma corrida ali não causa inconsistência, só uma escrita redundante no pior caso.
- O índice parcial cobre `WAITING/OPEN`. Se uma futura mudança de produto introduzir um novo status "ativo" (ex.: um status intermediário) sem atualizar a cláusula `WHERE` da migration E o array em `findActiveConversation()/upsertFromWebhook`, a proteção não cobriria o novo status — risco de manutenção, não de concorrência atual.
- `routeAutoAttendance()` e `assign()` fazem `update()` por id em conversa já existente — fora do escopo do B-49 (não criam linha nova), mas uma auditoria de "última escrita vence" nesses updates concorrentes não foi objeto desta análise.

15. Recomendações futuras

- Se um novo status "ativo" for adicionado ao enum `ConversationStatus`, atualizar a migration do índice parcial (nova migration, não editar a existente) e a lista em `findActiveConversation()` no mesmo commit.
- Considerar expor a métrica de "colisões resolvidas via P2002" (contador simples) em ambos `ConversationService` e `MessageService` — não existe hoje, e ajudaria a quantificar em produção com que frequência a concorrência genuína ocorre.

PRONTO PARA PRODUÇÃO
A implementação do B-48 segue o mesmo padrão de auditoria (mapear -> diagnosticar -> comparar -> decidir -> validar com concorrência real): recomenda-se manter esse padrão para qualquer novo caso de "encontra-ou-cria" que surgir no projeto.
A correção do B-49 elimina de forma definitiva, com garantia do PostgreSQL (não da aplicação), a possibilidade de duas conversas ativas para o mesmo contato. Validada com concorrência real de até 100 workers simultâneos, sem exceções não tratadas, sem regressão em nenhuma suíte de teste, sem alteração de regra de negócio, a correção é final e estável. Compatível com o pipeline de retry/DLQ do B-39 e com a correção de idempotência de mensagens do B-48.

16. Conclusão formal

Documento gerado automaticamente a partir de evidências coletadas ao vivo durante a sessão de correção (2026-08-01) — migration real, testes reais, script de concorrência real contra PostgreSQL.